

RÉPUBLIQUE DU CAMEROUN
REPUBLIC OF CAMEROON
Peace – Work – Fatherland

UNIVERSITÉ DE DSCHANG
UNIVERSITY OF DSCHANG
Scholae Thesaurus Dschangensis Ibi Cordum

BP 96, Dschang (Cameroun)
Tél./Fax : (237) 233 45 13 81
Website : <http://www.univ-dschang.org>
E-mail : udsrectorat@univ-dschang.org



FACULTÉ DES SCIENCES
FACULTY OF SCIENCES

Département de Mathématiques et
Informatique
*Department of Mathematics and
Computer Science*

BP 67, Dschang (Cameroun)
Tél. : (237) 233 45 17 35
Website : <http://fs.univ-dschang.org>
E-mail : dept_math-info@univ-dschang.org

Intelligence artificielle et gestion des micro-réseaux autonomes énergétiquement vert en milieux isolés dans une ville africaine : cas de la ville de N'Djamena (Tchad)

Par

OUEDDO KRIGA OKIM
CM-UDS-16SCI2090

Sous la direction de :

Dr RODRIGUES KWATE KWATE

PhD, Ingénieur-Architecte Solution TI, Québec, Canada, Université de Dschang, Cameroun

09 Septembre 2023

Plan

- 1 Introduction
- 2 Méthodologie
- 3 Implémentation et résultats
- 4 Conclusion



- 1 Introduction
- 2 Méthodologie
- 3 Implémentation et résultats
- 4 Conclusion



Les défis énergétiques

- L'Afrique connaît plusieurs défis énergétiques auxquels est confrontée la plupart des villes africaines en voie de développement et tel est le cas de la ville de N'Djamena, la capitale du Tchad.
- N'Djamena est confrontée aux défis tels que :
 - Croissance de la population
 - Dépendances aux énergies fossiles
 - Coupures fréquentes d'électricité
 - Coûts élevés de l'électricité
 - Potentiel des énergies renouvelables



Les défis énergétiques

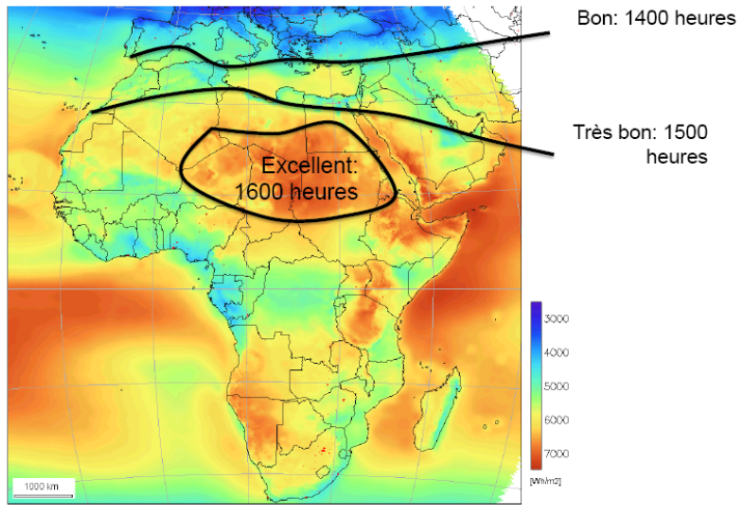


Figure: offre potentielle énergie solaire au Tchad, potentiel en Afrique



Notre Projet de micro-réseau autonome énergétiquement vert

Par définition, un micro-réseau autonome énergétiquement est :

- un système local de production, de distribution et de consommation d'énergie qui intègrent des sources d'énergie renouvelable et des technologies d'optimisation pour fournir une alimentation énergétique durable et autonome.
- généralement conçus pour fonctionner de manière indépendante du réseau électrique centralisé



Les hypothèses de la recherche

Comme hypothèses pour notre projet, on suppose que :

- Ce micro-réseau existe
- Il existe plusieurs sources de production d'énergie renouvelable dans ce micro-réseau
- Il existe les consommateurs qu'on a catégorisé en consommateurs domestiques, communautaires et enfin industriels
- Il existe des prosommateurs parmi les consommateurs



Les hypothèses de la recherche

Comme nous pouvons le voir :

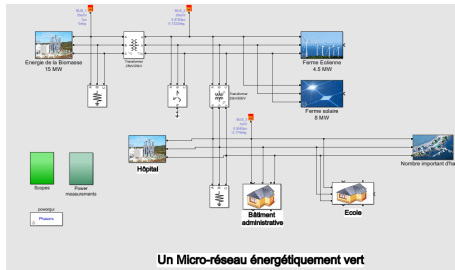


Figure: *Micro-réseau énergétiquement vert*



Problématique de notre projet

Notre Problématique

Comment maintenir l'équilibre entre l'offre et la demande en énergie de façon à ce que chacun trouve son compte ?



L'objectif principal

Notre objectif

L'objectif principal est de créer des **modèles d'intelligence** précis qui respectent au mieux la **planification énergétique**.



Les objectifs spécifiques

Comme objectifs spécifiques, on a :

- Modélisation de notre micro-réseau vert
- Utilisation de l'intelligence artificielle pour la prédiction de la charge électrique



- 1 Introduction
- 2 Méthodologie**
- 3 Implémentation et résultats
- 4 Conclusion



Définition

La modélisation de séries temporelles

Est une technique d'analyse de données qui consiste à comprendre, représenter et prévoir des données qui varient avec le temps. Une série temporelle est une séquence de données où chaque point de données est associé à un moment précis dans le temps.



Les modèles

Différents modèles statistiques et d'apprentissage automatique peuvent être utilisés pour modéliser des séries temporelles :

- le modèle ARIMA
- le modèle des réseaux de neurones récurrents (RNN)
- le modèle des LSTM
- le modèle de régression
- Et bien d'autres, etc



Validation du Modèle

Le modèle est généralement validé en utilisant des données de test pour évaluer ses performances. Les métriques souvent utilisées pour évaluer la précision du modèle:

- l'erreur quadratique moyenne (RMSE : Root Mean Squared Error)
- l'erreur absolue moyenne (MAE : Mean Absolute Error)

Prévision et Analyse :

Une fois validé, le modèle peut être utilisé pour effectuer des prévisions futures, ce qui peut être utile pour la planification et la prise de décision.



Pourquoi le RNN ?

- Les RNN sont conçus pour traiter des données séquentielles, telles que des **séries temporelles**, du texte ou de l'audio, où l'ordre des données est important.
- les RNN ont une "mémoire" interne qui leur permet de prendre en compte les informations précédentes lorsqu'ils traitent une nouvelle donnée de la séquence.
- Cette mémoire leur permet de modéliser des dépendances temporelles complexes, ce qui en fait un choix puissant pour des tâches telles que la **prédiction de séries temporelles**, la génération de texte, la traduction séquentielle, etc.



Les limites du RNN

Cependant, il convient de noter que les RNN ont des limitations telles que le "problème du gradient qui disparaît", qui ont conduit au développement de variantes plus avancées telles que les LSTM (Long Short-Term Memory) et les GRU (Gated Recurrent Unit) pour mieux gérer les dépendances à long terme.



Définition des LSTM

Les LSTM, ou "Long Short-Term Memory"

Sont une variante avancée des réseaux de neurones récurrents (RNN). Ils ont été spécialement conçus pour résoudre le problème du "problème du gradient qui disparaît" dans les RNN, ce qui les rend particulièrement adaptés à la modélisation de séquences de données complexes et à la gestion de dépendances à long terme.



Caractéristique des LSTM

- **Gestion de la Mémoire à Long Terme** : Les LSTM sont équipés d'une mémoire à long terme qui leur permet de stocker des informations importantes sur de longues séquences de données.
- **Portes de Sélection** : Les LSTM utilisent des "portes" pour contrôler le flux d'informations à travers le réseau. Il y a trois types de portes dans un LSTM :
 - Porte d'Oubli (Forget Gate)
 - Porte d'Entrée (Input Gate)
 - Porte de Sortie (Output Gate)
- **Gestion des Séquences de Données** : Grâce à leur mécanisme de portes, les LSTM peuvent gérer efficacement des séquences de données de différentes longueurs et modéliser des dépendances à long terme.



Définition du modèle

L'utilisation de ARIMA

le modèle ARIMA est utilisé pour décrire une série temporelle en termes de ses dépendances auto-régressives, de sa différenciation pour la rendre stationnaire et de sa moyenne mobile pour modéliser les erreurs de prédiction. Un modèle ARIMA est généralement noté sous la forme $ARIMA(p, d, q)$, où "p" est l'ordre de l'auto-régression, "d" est l'ordre de l'intégration et "q" est l'ordre de la moyenne mobile.

L'objectif principal du modèle ARIMA

Est de produire des prévisions précises en utilisant ces composants pour capturer les motifs temporels dans les données et ainsi améliorer la compréhension et la prévision de la série temporelle.



- 1 Introduction
- 2 Méthodologie
- 3 Implémentation et résultats**
- 4 Conclusion



Environnement d'implémentation

Pour l'implémentation, nous avons :

- Environnement matériel
- Environnement logiciel



Environnement logiciel

Comme logiciel, nous avons utilisé:

- l'IDE Anaconda
- le navigateur Firefox
- Matlab-Simulink 2016

Langage de programmation

Comme langage de programmation, nous avons utilisé le langage Python.



L'application du modèle ARIMA

Application 1

```
# Créer et ajuster le modèle ARIMA
p, d, q = 48, 0, 120 # Paramètres choisis
model = ARIMA(train_data, order=(p, d, q))
model_fit = model.fit()
# Faire des prédictions sur les données de test
predictions = model_fit.forecast(steps=len(test_data))
```



L'application du modèle LSTM

Application 2

```
# Créer et entraîner le modèle LSTM
model = Sequential()
model.add(LSTM(units=50, activation='relu', input_shape=(time_steps, 1)))
model.add(Dense(units=1))
model.compile(optimizer='adam', loss='mean_squared_error')
model.fit(X_train, y_train, epochs=100, batch_size=32)
```




Données utilisées

	Temperature	Humidity	vitesse_vent	GeneralDiffuseFlows	DiffuseFlows	charge_electrique
Datetime						
2017-01-01 00:00:00	6.559	73.8	0.083	0.051	0.119	70425.53544
2017-01-01 00:10:00	6.414	74.5	0.083	0.070	0.085	69320.84387
2017-01-01 00:20:00	6.313	74.5	0.080	0.062	0.100	67803.22193
2017-01-01 00:30:00	6.121	75.0	0.083	0.091	0.096	65489.23209
2017-01-01 00:40:00	5.921	75.7	0.081	0.048	0.085	63650.44627




Visualisation de la série temporelle


Série Temporelle de Charge électrique




Décomposition de la série temporelle




Décomposition de la série temporelle



Décomposition de la série temporelle



Analyse de la saisonnalité



Entraînement du modèle

Données d'entraînement

Nous avons pris les 80% premières observations de la série et les avons attribuées à l'ensemble d'entraînement.

Données de test

Nous avons pris les 20% dernières observations de la série et les avons attribuées à l'ensemble de test.



Evaluation des modèles

Modèle ARIMA

Après évaluation du modèle ARIMA en utilisant la métrique MAE (Mean Absolute Error), on obtient : 2914.931

Modèle LSTM

Après évaluation du modèle LSTM en utilisant la métrique RMSE (Root Mean Squared Error), on obtient : 3910.608



Autres modèles utilisés

Modèle Random Forest

Après évaluation du modèle en utilisant la métrique RMSE , on a obtenu :4315.88

Modèle Gradient Boosting

Après évaluation du modèle en utilisant la métrique RMSE, on a obtenu : 12296.08



Autres modèles utilisés

Modèle Linear Regression

Après évaluation du modèle en utilisant la métrique RMSE , on a obtenu :
14595.16

Modèle SVR ()

Après évaluation du modèle en utilisant la métrique RMSE, on a obtenu :
17035.45



Autres modèles utilisés

Modèle AdaBoost

Après évaluation du modèle en utilisant la métrique RMSE , on a obtenu : 13834.17

Modèle XGBoost

Après évaluation du modèle en utilisant la métrique RMSE, on a obtenu : 7126.58



Le meilleur des autres modèles

Random Forest: Root Mean Squared Error = 4315.88
Gradient Boosting: Root Mean Squared Error = 12296.08
Linear Regression: Root Mean Squared Error = 14595.16
SVR: Root Mean Squared Error = 17035.45
AdaBoost: Root Mean Squared Error = 13834.17
XGBoost: Root Mean Squared Error = 7126.58
Best Model: Random Forest



- 1 Introduction
- 2 Méthodologie
- 3 Implémentation et résultats
- 4 Conclusion**



Conclusion

- Problème : Le problème central que ce projet vise à résoudre est lié aux défis énergétiques auxquels est confrontée la ville de N'Djamena, la capitale du Tchad en créant des modèles d'intelligence précis qui respectent au mieux la planification énergétique.
- Pour venir à bout de ce problème, nous avons:
 - Fait un étude de la zone
 - Fait une caractérisation et une catégorisation du profil du consommateur de la ville de N'Djamena
 - Proposé une modélisation du micro-réseau énergétiquement vert
 - Proposé plusieurs modèles de prédiction de la charge électrique.



Perspectives

- Collecter les données réelles de consommations et de production d'un site quelconque
- Faire une optimisation pour maximiser le confort du consommateur.



Nous vous remercions pour votre
attention :-)

